

Phát Hiện Hành Động Con Người Sử Dụng Cảm Biến Gia Tốc và Mô Hình Transformer trong Hệ Thống IoT

Trịnh Hoàng Hà
Lớp: CNTT 16-01
MSV: 1671020098

Trịnh Thị Yến Mai
Lớp: CNTT 16-01
MSV: 1671020196

Nguyễn Thị Lan Anh
Lớp: CNTT 16-01
MSV: 1671020027

Mai Đức Hòa
Lớp: CNTT 16-01
MSV: 1671020121

15 tháng 3 năm 2025

Tóm tắt nội dung

Phát hiện hành động con người (HAR) là một lĩnh vực quan trọng với nhiều ứng dụng thực tiễn như chăm sóc sức khỏe, giám sát thể dục, và phát triển các hệ thống nhà thông minh. Nghiên cứu này đề xuất một phương pháp tiên tiến để nhận diện hành động con người trong thời gian thực bằng cách sử dụng dữ liệu từ cảm biến gia tốc và con quay hồi chuyển thu thập từ thiết bị ESP32, kết hợp với mô hình học sâu Transformer triển khai trong TensorFlow. Hệ thống được tích hợp trong khung IoT, sử dụng giao thức UDP để truyền dữ liệu hiệu quả từ thiết bị đến máy chủ. Chúng tôi đã phát triển một quy trình tiền xử lý dữ liệu cảm biến thô, bao gồm làm mịn, chuẩn hóa và tăng cường dữ liệu bằng các kỹ thuật nhiễu, biến đổi thời gian và thay đổi biên độ. Mô hình Transformer được huấn luyện để phân loại sáu hành động: đứng, ngồi, đi bộ, chạy bộ, ngã và nhảy, với độ chính xác vượt quá 90% trên tập kiểm tra. Hệ thống còn tích hợp giao diện người dùng đồ họa (GUI) để hiển thị kết quả dự đoán và biểu đồ cảm biến theo thời gian thực. Kết quả thử nghiệm cho thấy hiệu suất mạnh mẽ và ổn định, phù hợp cho việc triển khai thực tế trong các ứng dụng IoT.

Từ khóa

Phát hiện hành động con người, Mô hình Transformer, IoT, Cảm biến gia tốc, ESP32, Dự đoán thời gian thực

1 Giới thiệu

Phát hiện hành động con người (Human Activity Recognition - HAR) là một lĩnh vực nghiên cứu quan trọng trong khoa học máy tính và kỹ thuật, cho phép nhận diện và phân loại các hoạt động thể chất dựa trên dữ liệu cảm biến [1]. Các ứng dụng của HAR rất đa dạng, bao gồm giám sát sức khỏe cho người cao tuổi, theo dõi hiệu suất thể thao, phát hiện tình trạng ngã trong y tế, và điều khiển thông minh trong các hệ thống nhà tự động. Với sự phát triển mạnh mẽ của công nghệ Internet vạn vật (IoT), việc tích hợp các cảm biến nhỏ gọn như gia tốc kế và con quay hồi chuyển với các thuật toán học sâu đã mở ra cơ hội nâng cao độ chính xác, hiệu quả và tính thực tiễn của các hệ thống HAR trong đời sống hàng ngày.

Trong các phương pháp truyền thống, HAR thường dựa vào việc trích xuất thủ công các đặc trưng từ dữ liệu cảm biến, chẳng hạn như giá trị

trung bình, phương sai, hoặc biên độ tín hiệu, sau đó áp dụng các thuật toán học máy cổ điển như Máy Vector Hỗ trợ (SVM) hoặc Mô hình Markov Ẩn (HMM) để phân loại [3]. Tuy nhiên, những phương pháp này có nhiều hạn chế. Thứ nhất, quá trình trích xuất đặc trưng đòi hỏi kiến thức chuyên môn sâu và tốn thời gian. Thứ hai, chúng thường không hiệu quả trong việc xử lý các chuỗi dữ liệu thời gian phức tạp, đặc biệt khi các hành động có sự tương đồng về tín hiệu (ví dụ: đi bộ và chạy bộ) hoặc khi dữ liệu bị nhiễu bởi các yếu tố ngoại cảnh. Sự ra đời của học sâu đã mang lại bước tiến vượt bậc, với các mô hình như Mạng Nơ-ron Tích chập (CNN) và Mạng Nơ-ron Hồi tiếp (RNN) cho phép học trực tiếp từ dữ liệu thô mà không cần trích xuất đặc trưng thủ công [4]. Gần đây hơn, mô hình Transformer – vốn nổi tiếng trong xử lý ngôn ngữ tự nhiên – đã được áp dụng thành công cho các tác vụ chuỗi thời gian nhờ cơ chế chú ý (attention) mạnh mẽ, giúp nắm bắt các phụ thuộc dài hạn một cách hiệu quả [2].

Nghiên cứu này đề xuất một hệ thống HAR dựa trên IoT, tận dụng dữ liệu từ cảm biến gia tốc và con quay hồi chuyển của thiết bị ESP32 – một nền tảng nhúng nhỏ gọn, giá rẻ và phổ biến trong cộng đồng phát triển IoT. Dữ liệu được truyền qua giao thức UDP đến máy chủ, nơi nó được xử lý bởi mô hình Transformer triển khai trong TensorFlow. Hệ thống không chỉ dự đoán hành động theo thời gian thực với độ tin cậy cao mà còn cung cấp giao diện người dùng đồ họa (GUI) để hiển thị kết quả và biểu đồ cảm biến, hỗ trợ người dùng theo dõi trực quan. Các đóng góp chính của nghiên cứu bao gồm:

- Một quy trình tiền xử lý dữ liệu cảm biến toàn diện, bao gồm làm mịn tín hiệu bằng bộ lọc Savitzky-Golay, chuẩn hóa dữ liệu bằng StandardScaler, và tăng cường dữ liệu để cải thiện độ bền của mô hình.
- Thiết kế và huấn luyện một mô hình Transformer tối ưu cho phân loại chuỗi thời gian từ dữ liệu cảm biến, với khả năng phân biệt sáu hành động khác nhau.
- Phát triển khung IoT sử dụng giao thức UDP để truyền dữ liệu hiệu quả giữa ESP32 và máy chủ, đảm bảo tính thời gian thực.

- Triển khai cơ chế dự đoán thời gian thực với thuật toán làm mịn dựa trên trung bình trượt có trọng số, tăng cường độ ổn định của kết quả trong môi trường thực tế.

Phần còn lại của bài báo sẽ trình bày chi tiết phương pháp luận, kết quả thử nghiệm, thảo luận về hiệu suất và các hướng phát triển trong tương lai.

2 Các Nghiên Cứu Liên Quan

Nghiên cứu về HAR đã trải qua nhiều giai đoạn phát triển, từ các phương pháp truyền thống dựa trên thống kê đến các cách tiếp cận hiện đại sử dụng học sâu. Trong giai đoạn đầu, các công trình tập trung vào việc sử dụng các đặc trưng được trích xuất thủ công từ dữ liệu cảm biến, chẳng hạn như biên độ tín hiệu, tần số hoặc năng lượng, kết hợp với các thuật toán học máy như SVM, K-Nearest Neighbors (KNN), hoặc Decision Trees [3]. Những phương pháp này tuy đơn giản và dễ triển khai trên các thiết bị có tài nguyên hạn chế, nhưng đòi hỏi quá trình trích xuất đặc trưng phức tạp và thường không hiệu quả khi xử lý các tập dữ liệu lớn, đa dạng hoặc chứa nhiễu.

Sự xuất hiện của học sâu đã đánh dấu một bước ngoặt trong lĩnh vực HAR. Các mô hình CNN được sử dụng để tự động trích xuất đặc trưng không gian từ dữ liệu cảm biến, giảm bớt sự phụ thuộc vào thiết kế đặc trưng thủ công. Trong khi đó, RNN, đặc biệt là LSTM, tỏ ra vượt trội trong việc mô hình hóa các phụ thuộc thời gian ngắn hạn, giúp nhận diện các hành động có tính tuần tự như đi bộ hoặc chạy bộ [4]. Tuy nhiên, cả hai loại mô hình này đều có những hạn chế đáng kể. CNN không thể xử lý tốt các phụ thuộc dài hạn trong dữ liệu thời gian, trong khi RNN thường gặp vấn đề về gradient biến mất hoặc bùng nổ khi chuỗi dữ liệu quá dài, dẫn đến khó khăn trong việc huấn luyện trên các tập dữ liệu phức tạp.

Mô hình Transformer, được giới thiệu bởi Vaswani và cộng sự vào năm 2017 [2], đã mang lại một giải pháp đột phá. Ban đầu được thiết kế cho xử lý ngôn ngữ tự nhiên, Transformer sử dụng cơ chế chú ý đa đầu (multi-head attention) để tập trung đồng thời vào nhiều phần khác nhau

của chuỗi dữ liệu, khắc phục hạn chế của RNN về phụ thuộc dài hạn và của CNN về phạm vi không gian. Trong những năm gần đây, Transformer đã được áp dụng ngày càng nhiều cho các tác vụ chuỗi thời gian, bao gồm cả HAR, nhờ khả năng học các mẫu phức tạp mà không cần cấu trúc tuần tự cố định.

Trong bối cảnh IoT, các hệ thống HAR thường ưu tiên các mô hình nhẹ để triển khai trên thiết bị nhúng như ESP32 hoặc Arduino, nhằm giảm độ trễ và tiêu thụ năng lượng. Tuy nhiên, với sự phát triển của phần cứng và các kỹ thuật tối ưu hóa thuật toán, các mô hình phức tạp như Transformer đã bắt đầu được thử nghiệm trong các ứng dụng thời gian thực. Nghiên cứu của chúng tôi nổi bật ở chỗ kết hợp mô hình Transformer với hệ thống IoT, tận dụng khả năng xử lý dữ liệu từ ESP32 theo thời gian thực và cung cấp giao diện trực quan cho người dùng, mở ra tiềm năng ứng dụng trong các lĩnh vực như y tế, thể thao và an ninh.

3 Phương Pháp

3.1 Kiến Trúc Hệ Thống

Hệ thống được xây dựng dựa trên ba thành phần chính, tạo thành một quy trình khép kín từ thu thập dữ liệu đến dự đoán hành động:

1. **Thu Thập Dữ Liệu:** Thiết bị ESP32, được tích hợp cảm biến gia tốc và con quay hồi chuyển, thu thập dữ liệu ở tần số 50 Hz (tức 50 mẫu mỗi giây). Dữ liệu được định dạng dưới dạng JSON với sáu trường (AccelX, AccelY, AccelZ, GyroX, GyroY, GyroZ) và truyền qua giao thức UDP đến máy chủ tại địa chỉ IP mặc định 192.168.52.147, sử dụng dải cổng từ 8080 đến 8090. UDP được chọn nhờ tốc độ truyền cao và phù hợp với ứng dụng thời gian thực, dù không đảm bảo thứ tự gói tin.
2. **Xử Lý Dữ Liệu:** Dữ liệu thô từ ESP32 được xử lý qua ba giai đoạn chính: làm mịn để loại bỏ nhiễu, chuẩn hóa để đưa về phân phối chuẩn, và phân đoạn thành các chuỗi thời gian để chuẩn bị cho mô hình học sâu. Các bước này sẽ được trình bày chi tiết ở phần sau.

3. **Dự Đoán Hành Động:** Mô hình Transformer nhận các chuỗi dữ liệu đã xử lý, thực hiện suy luận để dự đoán hành động, và áp dụng thuật toán làm mịn dựa trên trung bình trượt có trọng số để tăng độ ổn định của kết quả. Kết quả cuối cùng được hiển thị qua giao diện người dùng đồ họa (GUI) trên máy chủ.

3.2 Tiền Xử Lý Dữ Liệu

Dữ liệu cảm biến thô từ ESP32 bao gồm sáu kênh: ba trục gia tốc (AccelX, AccelY, AccelZ) đo gia tốc tuyến tính (m/s^2) và ba trục con quay hồi chuyển (GyroX, GyroY, GyroZ) đo vận tốc góc (rad/s). Do dữ liệu thô thường chứa nhiễu từ môi trường hoặc chuyển động không mong muốn, một quy trình tiền xử lý toàn diện được thực hiện như sau:


- **Làm Mịn:** Bộ lọc Savitzky-Golay được áp dụng với kích thước cửa sổ 5 mẫu và bậc đa thức 2. Bộ lọc này sử dụng phương pháp nội suy đa thức để làm mịn dữ liệu, loại bỏ nhiễu ngẫu nhiên mà vẫn bảo toàn xu hướng tín hiệu – một ưu điểm vượt trội so với trung bình trượt thông thường vốn có thể làm mất chi tiết tín hiệu.
- **Chuẩn Hóa:** StandardScaler từ thư viện Scikit-learn được sử dụng để chuẩn hóa dữ liệu về trung bình 0 và phương sai 1. Các tham số chuẩn hóa (mean và scale) được lưu vào tệp `scaler_params.npz` để tái sử dụng trong giai đoạn suy luận, đảm bảo tính nhất quán giữa huấn luyện và dự đoán.
- **Tạo Chuỗi:** Dữ liệu liên tục được phân đoạn thành các chuỗi 32 mẫu với stride (bước trượt) 16, tạo ra sự chồng lấp 50% giữa các chuỗi. Độ dài 32 mẫu tương ứng với 0.64 giây dữ liệu ở tần số 50 Hz, đủ để nắm bắt các mẫu hành động ngắn hạn, trong khi stride 16 cân bằng giữa tính liên tục và hiệu quả tính toán.
- **Tăng Cường Dữ Liệu:** Để cải thiện độ bền của mô hình trước các biến đổi thực tế, dữ liệu huấn luyện được tăng cường bằng ba kỹ thuật: (1) Thêm nhiễu ngẫu nhiên với noise factor 0.05 để mô phỏng nhiễu môi trường; (2)

Biến đổi thời gian (time warping) với sigma 0.2 để thay đổi tốc độ hành động; (3) Thay đổi biên độ (magnitude scaling) với sigma 0.1 để mô phỏng cường độ khác nhau của cùng một hành động.

3.3 Mô Hình Transformer

Mô hình Transformer được thiết kế đặc biệt cho phân loại chuỗi thời gian, với cấu trúc chi tiết như sau (xem Hình 1):

- **Mã Hóa Vị Trí:** Một lớp Embedding thêm thông tin vị trí vào mỗi mẫu trong chuỗi 32 mẫu, giúp mô hình nhận biết thứ tự thời gian của dữ liệu – một yếu tố quan trọng trong các tác vụ chuỗi thời gian không tuần tự như HAR.
- **Khối Transformer:** Hai khối Transformer được xếp chồng, mỗi khối bao gồm: (1) MultiHeadAttention với 4 đầu chú ý và key_dim 6 (tương ứng với 6 kênh dữ liệu), cho phép mô hình tập trung vào các phần khác nhau của chuỗi; (2) Mạng feed-forward với chiều 32 và hàm kích hoạt ReLU; (3) Hai lớp LayerNormalization để ổn định huấn luyện; (4) Dropout với tỷ lệ 0.1 để giảm overfitting.
- **Lớp Đầu Ra:** Sau khi đi qua hai khối Transformer, dữ liệu được giảm chiều bằng GlobalAveragePooling1D, sau đó truyền qua một lớp Dense với 64 đơn vị và hàm ReLU, dropout 0.3, và cuối cùng là lớp Dense với 6 đơn vị và hàm softmax để dự đoán xác suất của 6 lớp hành động (đứng, ngồi, đi bộ, chạy bộ, ngã, nhảy).



Hình 1: Kiến trúc của mô hình Transformer.

Mô hình được huấn luyện với bộ tối ưu Adam (learning rate ban đầu $1e-4$), hàm mất mát sparse categorical cross-entropy, và các callback

như EarlyStopping (patience 15) để dừng sớm nếu không cải thiện độ chính xác trên tập xác thực, và ReduceLROnPlateau (factor 0.5, min_lr $1e-6$) để giảm tốc độ học khi hiệu suất ngừng tăng.

3.4 Dự Đoán Thời Gian Thực

Lớp ActivityPredictor được thiết kế để quản lý toàn bộ quy trình dự đoán thời gian thực:

- **Nhận Dữ Liệu:** Socket UDP lắng nghe dữ liệu từ ESP32 trên dải cổng 8080-8090, xử lý các gói JSON và lưu vào bộ đệm trượt (deque) với kích thước tối đa 128 mẫu. Nếu kết nối thất bại, hệ thống chuyển sang chế độ mô phỏng dữ liệu ngẫu nhiên để duy trì hoạt động.
- **Dự Đoán:** Cứ mỗi 2 giây (100 mẫu ở 50 Hz), dữ liệu từ bộ đệm được phân đoạn thành chuỗi 32 mẫu, chuẩn hóa bằng scaler đã lưu, và đưa vào mô hình Transformer để suy luận theo lô (batch size 4). Kết quả bao gồm chỉ số hành động (0-5) và độ tin cậy (confidence) dựa trên xác suất softmax.
- **Làm Mịn:** Một cửa sổ trượt 7 dự đoán được sử dụng với trọng số tuyến tính từ 0.6 đến 1.0 (tăng dần theo thời gian), kết hợp ngưỡng tin cậy tối thiểu 0.3 và ngưỡng dự đoán 0.3 để xác định hành động cuối cùng. Điều này giảm thiểu dao động trong dự đoán khi tín hiệu thay đổi nhanh.
- **Hiển Thị:** GUI dựa trên Tkinter hiển thị thông tin theo thời gian thực, bao gồm tên hành động, độ tin cậy (%), độ ổn định (Cao/Trung bình/Thấp), thời gian suy luận (ms), và hai biểu đồ: gia tốc (3 trục) và con quay hồi chuyển (3 trục).

4 Thử Nghiệm

4.1 Tập Dữ Liệu

Tập dữ liệu được thu thập từ thiết bị ESP32, bao gồm các phép đo từ nhiều đối tượng thực hiện sáu hành động: đứng, ngồi, đi bộ, chạy bộ, ngã và nhảy. Mỗi hành động được gán nhãn số từ 0 đến 5 theo

ánh xạ trong tệp `activity_mapping.csv`. Dữ liệu thô ban đầu được lưu trong thư mục `raw_data`, sau đó được xử lý (làm mịn, chuẩn hóa) và lưu vào `processed_data`. Sau khi tăng cường bằng các kỹ thuật nhiễu, biến đổi thời gian và thay đổi biên độ, tập huấn luyện chứa hơn 10.000 chuỗi, trong đó 80% được dùng để huấn luyện và 20% để kiểm tra. Phân chia được thực hiện bằng hàm `train_test_split` với tham số `stratify` để đảm bảo phân bố nhãn đồng đều giữa các tập.

4.2 Huấn Luyện

Mô hình được huấn luyện trên máy chủ có GPU, sử dụng TensorFlow 2.x với cấu hình sau:

- **Thông số huấn luyện:** 50 epoch, batch size 64, optimizer Adam với learning rate $1e-4$.
- **Callbacks:** - EarlyStopping với patience 15, khôi phục trọng số tốt nhất nếu độ chính xác trên tập xác thực không tăng. - ReduceLROnPlateau với factor 0.5 và min_lr $1e-6$, giảm learning rate khi hiệu suất chững lại. - SafeInterruptCallback cho phép dừng an toàn bằng Ctrl+C, lưu trạng thái mô hình nếu bị gián đoạn.
- **Chuẩn bị mô hình:** Trước khi huấn luyện, mô hình được "warm up" bằng một lần dự đoán trên dữ liệu giả lập để tối ưu hóa hiệu suất suy luận.

Mô hình cuối cùng được lưu dưới dạng `transformer_model.h5` trong thư mục `processed_data`.

4.3 Kết Quả


Hiệu suất của mô hình được đánh giá trên tập kiểm tra, với các chỉ số chính được trình bày trong Bảng 1. Độ chính xác tổng thể đạt 92.4%, với thời gian suy luận trung bình 15.8 ms trên mỗi dự đoán. Độ ổn định được định nghĩa là tỷ lệ dự đoán đạt mức "Cao" (stability > 0.8), chiếm 85.6% tổng số trường hợp.

Ma trận nhầm lẫn (Hình 2) cho thấy mô hình phân loại tốt các hành động tĩnh như đứng (95.2%)

Bảng 1: Hiệu suất trên tập kiểm tra

Chỉ số	Giá trị	Đơn vị
Độ chính xác tổng thể	92.4	%
Thời gian suy luận trung bình	15.8	ms
Độ ổn định (Cao)	85.6	%
Độ chính xác - Đứng	95.2	%
Độ chính xác - Ngồi	94.8	%
Độ chính xác - Đi bộ	91.5	%
Độ chính xác - Chạy bộ	90.1	%
Độ chính xác - Ngã	93.7	%
Độ chính xác - Nhảy	89.3	%

và ngồi (94.8%), cũng như các hành động đặc trưng như ngã (93.7%). Tuy nhiên, có một số nhầm lẫn giữa đi bộ (91.5%) và chạy bộ (90.1%) do sự tương đồng về mẫu tín hiệu gia tốc và con quay hồi chuyển trong hai hành động này.



Hình 2: Ma trận nhầm lẫn của dự đoán trên tập kiểm tra.

5 Thảo Luận

Mô hình Transformer trong nghiên cứu này thể hiện hiệu suất vượt trội so với các phương pháp truyền thống như CNN và RNN nhờ cơ chế chú ý đa đầu, cho phép nhận diện các mẫu thời gian phức tạp trong dữ liệu cảm biến. So với CNN, Transformer không bị giới hạn bởi kích thước cửa sổ trượt cố định, giúp nắm bắt các phụ thuộc dài hạn hiệu quả hơn. So với RNN, nó tránh được vấn đề gradient

biến mất hoặc bùng nổ, cải thiện khả năng huấn luyện trên các chuỗi dài. Độ chính xác 92.4% trên tập kiểm tra cho thấy mô hình phù hợp với các ứng dụng thực tế như giám sát sức khỏe, phát hiện ngã hoặc theo dõi hoạt động thể thao.

Việc tích hợp hệ thống với IoT thông qua ESP32 và giao thức UDP mang lại lợi thế về tốc độ và tính thời gian thực. UDP cho phép truyền dữ liệu với độ trễ thấp, phù hợp với các ứng dụng yêu cầu phản hồi nhanh. Tuy nhiên, thời gian suy luận trung bình 15.8 ms vẫn là một thách thức khi xem xét triển khai trên các thiết bị nhúng với tài nguyên hạn chế như ESP32, vốn không đủ sức mạnh tính toán để chạy mô hình Transformer trực tiếp. Cơ chế làm mịn với cửa sổ trượt 7 dự đoán đã cải thiện đáng kể độ ổn định (85.6% đạt mức "Cao"), giảm thiểu sai lệch trong các tình huống thực tế nơi tín hiệu có thể bị nhiễu bởi chuyển động không mong muốn hoặc thay đổi đột ngột.

Một số thách thức và hạn chế cần được xem xét:

- **Tối ưu hóa hiệu suất:** Mô hình hiện tại yêu cầu tài nguyên tính toán cao, đòi hỏi máy chủ với GPU để suy luận hiệu quả. Để triển khai trên ESP32, cần áp dụng các kỹ thuật nén mô hình như pruning (cắt tỉa) hoặc quantization (lượng tử hóa).
- **Tính tổng quát:** Tập dữ liệu hiện tại chủ yếu thu thập từ một số đối tượng trong điều kiện kiểm soát, chưa đủ đa dạng để đại diện cho các nhóm tuổi khác nhau (ví dụ: trẻ em, người cao tuổi) hoặc các môi trường thực tế phức tạp (địa hình không bằng phẳng, nhiễu rung động).
- **Kết nối mạng:** Giao thức UDP tuy nhanh nhưng không đảm bảo thứ tự gói tin hoặc độ tin cậy, có thể dẫn đến mất dữ liệu trong các mạng không ổn định. Một giải pháp thay thế như TCP có thể được cân nhắc, dù sẽ tăng độ trễ.
- **Ứng dụng thực tế:** Hệ thống hiện tại tập trung vào sáu hành động cơ bản. Để mở rộng phạm vi ứng dụng, cần bổ sung các hành động khác như leo cầu thang, đạp xe hoặc các hoạt động phức hợp.

So sánh với các nghiên cứu khác, hệ thống của chúng tôi nổi bật ở khả năng kết hợp IoT với mô hình Transformer tiên tiến và giao diện GUI trực quan. Tuy nhiên, để cạnh tranh với các mô hình nhẹ hơn trong bối cảnh IoT, việc tối ưu hóa kích thước và tốc độ của mô hình là cần thiết.

6 Kết Luận

Nghiên cứu này đã phát triển thành công một hệ thống HAR tích hợp IoT và học sâu dựa trên Transformer, đạt độ chính xác tổng thể 92.4% và khả năng dự đoán thời gian thực ổn định với 85.6% kết quả ở mức "Cao". Hệ thống tận dụng dữ liệu từ cảm biến gia tốc và con quay hồi chuyển của ESP32, xử lý qua mô hình Transformer mạnh mẽ triển khai trong TensorFlow, và cung cấp giao diện GUI thân thiện dựa trên Tkinter. Kết quả thử nghiệm cho thấy tiềm năng ứng dụng thực tế trong các lĩnh vực như giám sát sức khỏe, phát hiện ngã, và theo dõi hoạt động thể chất, đồng thời mở ra một hướng đi mới cho việc sử dụng các mô hình học sâu tiên tiến trong các hệ thống IoT.

Trong tương lai, chúng tôi dự định tập trung vào hai hướng phát triển chính. Thứ nhất, tối ưu hóa mô hình bằng các kỹ thuật nén như model pruning và quantization để triển khai trực tiếp trên thiết bị nhúng như ESP32, giảm phụ thuộc vào máy chủ và cải thiện tính di động của hệ thống. Thứ hai, mở rộng tập dữ liệu bằng cách thu thập thêm dữ liệu từ nhiều đối tượng, độ tuổi và kịch bản thực tế hơn (ví dụ: trong nhà, ngoài trời, trên các bề mặt khác nhau), nhằm nâng cao tính tổng quát và khả năng thích nghi của mô hình. Ngoài ra, việc tích hợp các cảm biến khác (như áp suất khí quyển hoặc nhịp tim) có thể được xem xét để tăng cường khả năng nhận diện các hành động phức tạp hơn, mở rộng phạm vi ứng dụng của hệ thống.

Tài liệu

- [1] A. Bulling, U. Blanke, và B. Schiele, "Hướng dẫn về phát hiện hành động con người sử dụng cảm biến quán tính đeo trên người," *ACM Comput. Surv.*, vol. 46, no. 3, pp. 1–33, 2014.

- [2] A. Vaswani và cộng sự, "Chú ý là tất cả những gì bạn cần," trong *Proc. NeurIPS*, 2017, pp. 5998–6008.
- [3] L. Bao và S. S. Intille, "Phát hiện hành động từ dữ liệu gia tốc được chú thích bởi người dùng," trong *Proc. Pervasive*, 2004, pp. 1–17.
- [4] F. J. Ordóñez và D. Roggen, "Mạng nơ-ron tích chập sâu và hồi tiếp LSTM cho phát hiện hành động đa phương thức từ thiết bị đeo," *Sensors*, vol. 16, no. 1, p. 115, 2016.